

Nama(NIM) : Abdillah Muharrarul(053), Panji Bachtiar(029), Ananda Nouval(071)

Judul Proyek: Sistem Klasifikasi Spam pada Pesan Email Berbahasa Indonesia Menggunakan IndoBERT Berbasis Web

Deskripsi Proyek: Proyek ini bertujuan membangun sistem deteksi email spam secara otomatis menggunakan teknologi Machine Learning berbasis Deep Learning. Sistem memanfaatkan model IndoBERT untuk memahami konteks bahasa Indonesia dan mengklasifikasikan email ke dalam dua kategori, yaitu spam dan ham (bukan spam).

Aplikasi dikembangkan menggunakan framework Hugging Face Transformers untuk proses pelatihan model dan Streamlit sebagai antarmuka web agar pengguna dapat melakukan deteksi spam secara real-time. Sistem diharapkan mampu membantu pengguna menyaring email berbahaya, promosi yang tidak diinginkan, serta upaya phishing dengan tingkat akurasi yang tinggi.

Definisi Sistem:

Input	Teks isi email berbahasa Indonesia
Proses	Preprocessing teks, tokenisasi menggunakan IndoBERT Tokenizer, klasifikasi menggunakan model IndoBERT yang telah ditraining
Output	Hasil klasifikasi email berupa kategori Spam atau Ham (Bukan Spam) beserta conf score

Alur Penyelesaian: (*Di dalam jurnal tidak ada diagram penelitian)

1. Pengumpulan Dataset

Dataset yang digunakan adalah *Indonesian Email Spam Dataset* yang tersedia secara publik di Kaggle: <https://www.kaggle.com/datasets/gevabriel/indonesian-email-spam> berisi pesan email berbahasa Indonesia berlabel spam dan ham.

2. Preprocessing Data

Dilakukan pembersihan teks meliputi:

- Mengubah huruf menjadi lowercase
- Menghapus karakter non-alfabet
- Menghapus URL

- d. Menghapus spasi berlebih
 - e. Membersihkan simbol dan karakter tidak penting
3. Tokenisasi

Teks diubah menjadi token menggunakan IndoBERT Tokenizer agar dapat diproses oleh model Transformer.

4. Split Dataset

Data Training = 80%, Data Validation = 12%, dan Data Testing = 8%. Pembagian dilakukan untuk menghindari overfitting dan mengukur kemampuan generalisasi model.

5. Pelatihan Model

Model IndoBERT dilatih menggunakan:

- a. Hugging Face Transformers
 - b. PyTorch
 - c. Learning Rate = 3×10^{-5}
 - d. Epoch = 10
6. Evaluasi Model

Model dievaluasi menggunakan Accuracy, Precision, Recall, F1-Score dan Confusion Matrix

7. Implementasi Web

Model yang telah dilatih diintegrasikan ke aplikasi web menggunakan Streamlit sehingga pengguna dapat: Mengecek satu email (single prediction) atau Mengecek banyak email sekaligus melalui CSV (bulk prediction)

Referensi :

Supono, Riza Adriati, and Muhammad Irgi Imani. "Implementasi Machine Learning untuk Klasifikasi Email Spam Menggunakan Indobert, Hugging Face Transformers dan Streamlit." *Jurnal Sosial dan Teknologi (SOSTECH)*, vol. 6, no. 1, 1 Januari 2026, <https://doi.org/10.59188/jurnalsostech.v6i1.32659>.